Introduction à l'Intelligence Artificielle

Des données vers la connaissance

L'IA en entreprise : un potentiel encore sous-exploité

Digitalisation & adoption de l'intelligence Artificielle

TPE	PME	ETI
< 5%	~ 15%	~ 35%
des très petites entreprises utilisent l'IA en 2024	des PME ont initié une démarche IA	des ETI intègrent des outils IA

Taux d'adoption moyen estimé en France (toutes tailles)

~18% | 82% des entreprises françaises n'utilisent pas encore l'IA

Principaux freins

- *Manque de compétences internes*
- *Coût perçu comme trop élevé*
- Méconnaissance des solutions disponibles

RÉPUBLIQUE FRANÇAISE
Liberté Égalité Fraternité

Osez l'IA

Benjamin Allaert

Benjamin.allaert@imt-nord-europe.fr

Bureau D107S

Ambassadeur IA Hauts-de-France

Programme

FACE À FACE

Concepts & Fondamentaux

- Introduction à l'Intelligence Artificielle
- Etude des paradigmes d'apprentissage
- Introduction à Pytorch

Apprentissage des concepts

1

2

CLASSES VIRTUELLES

Mise en pratique

- Chargement & preparation des données
- Optimisation des hyperparamètres
- Courbes d'apprentissage
- Machine vs Deep Learning
- Stratégies de modélisation

PyTorch niv. 1 & 2 · Protocole d'évaluation

3

FACE À FACE

Data Challenge

- Préparation du challenge
- Compétition en équipe
- Optimisation des scores

Teamwork · Mise en compétition

4

JURY

Oral Final

- Présentation des résultats
- Scores & analyse

Présentation devant jury

Evolution des approches

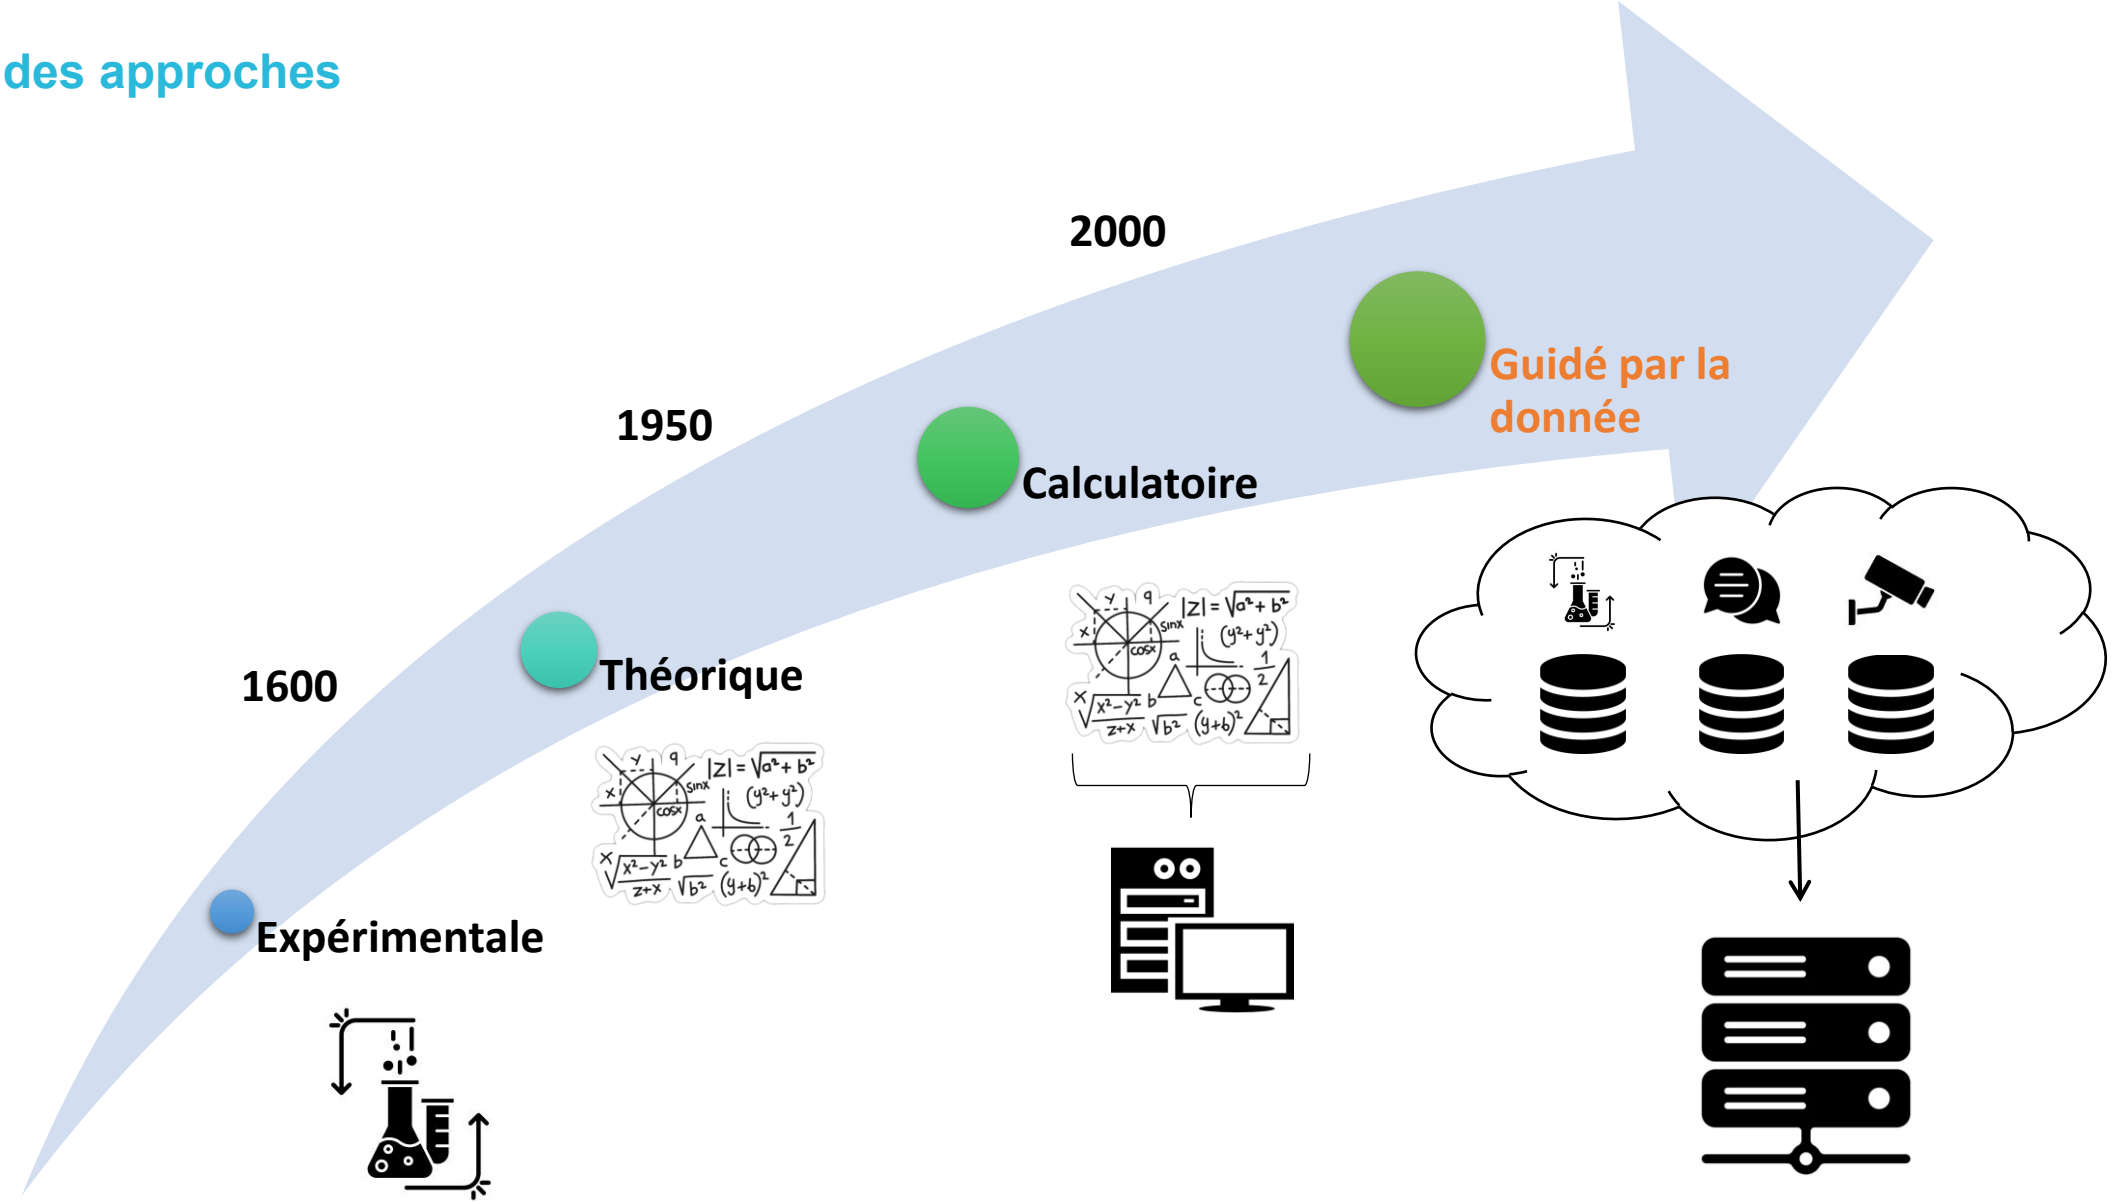

1940 – 1960

Naissance de l'IA

1970 – 1990

Début de l'IA d'aujourd'hui

2010

L'IA Nouvelle Génération

2020

Démocratisation de l'IA

1952** : 1er logiciel qui joue **aux échecs

***1968** : **IBM Deep Blue** bat le champion d'échecs Kasparov*

***2013** : Word Embedding*

***2016** : **AlphaGo** (Deepmind) Champion du monde du jeu de Go*

2018** : Invention des modèles **Transformers

2020** : Lancement de GPT-3 par **OpenAI

***2021** : **DALL-E** permet de générer des images*

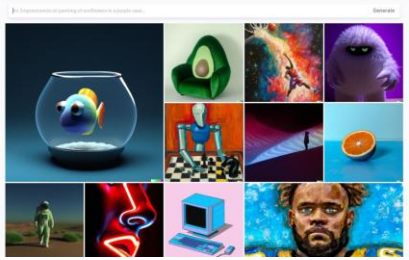

Catégories

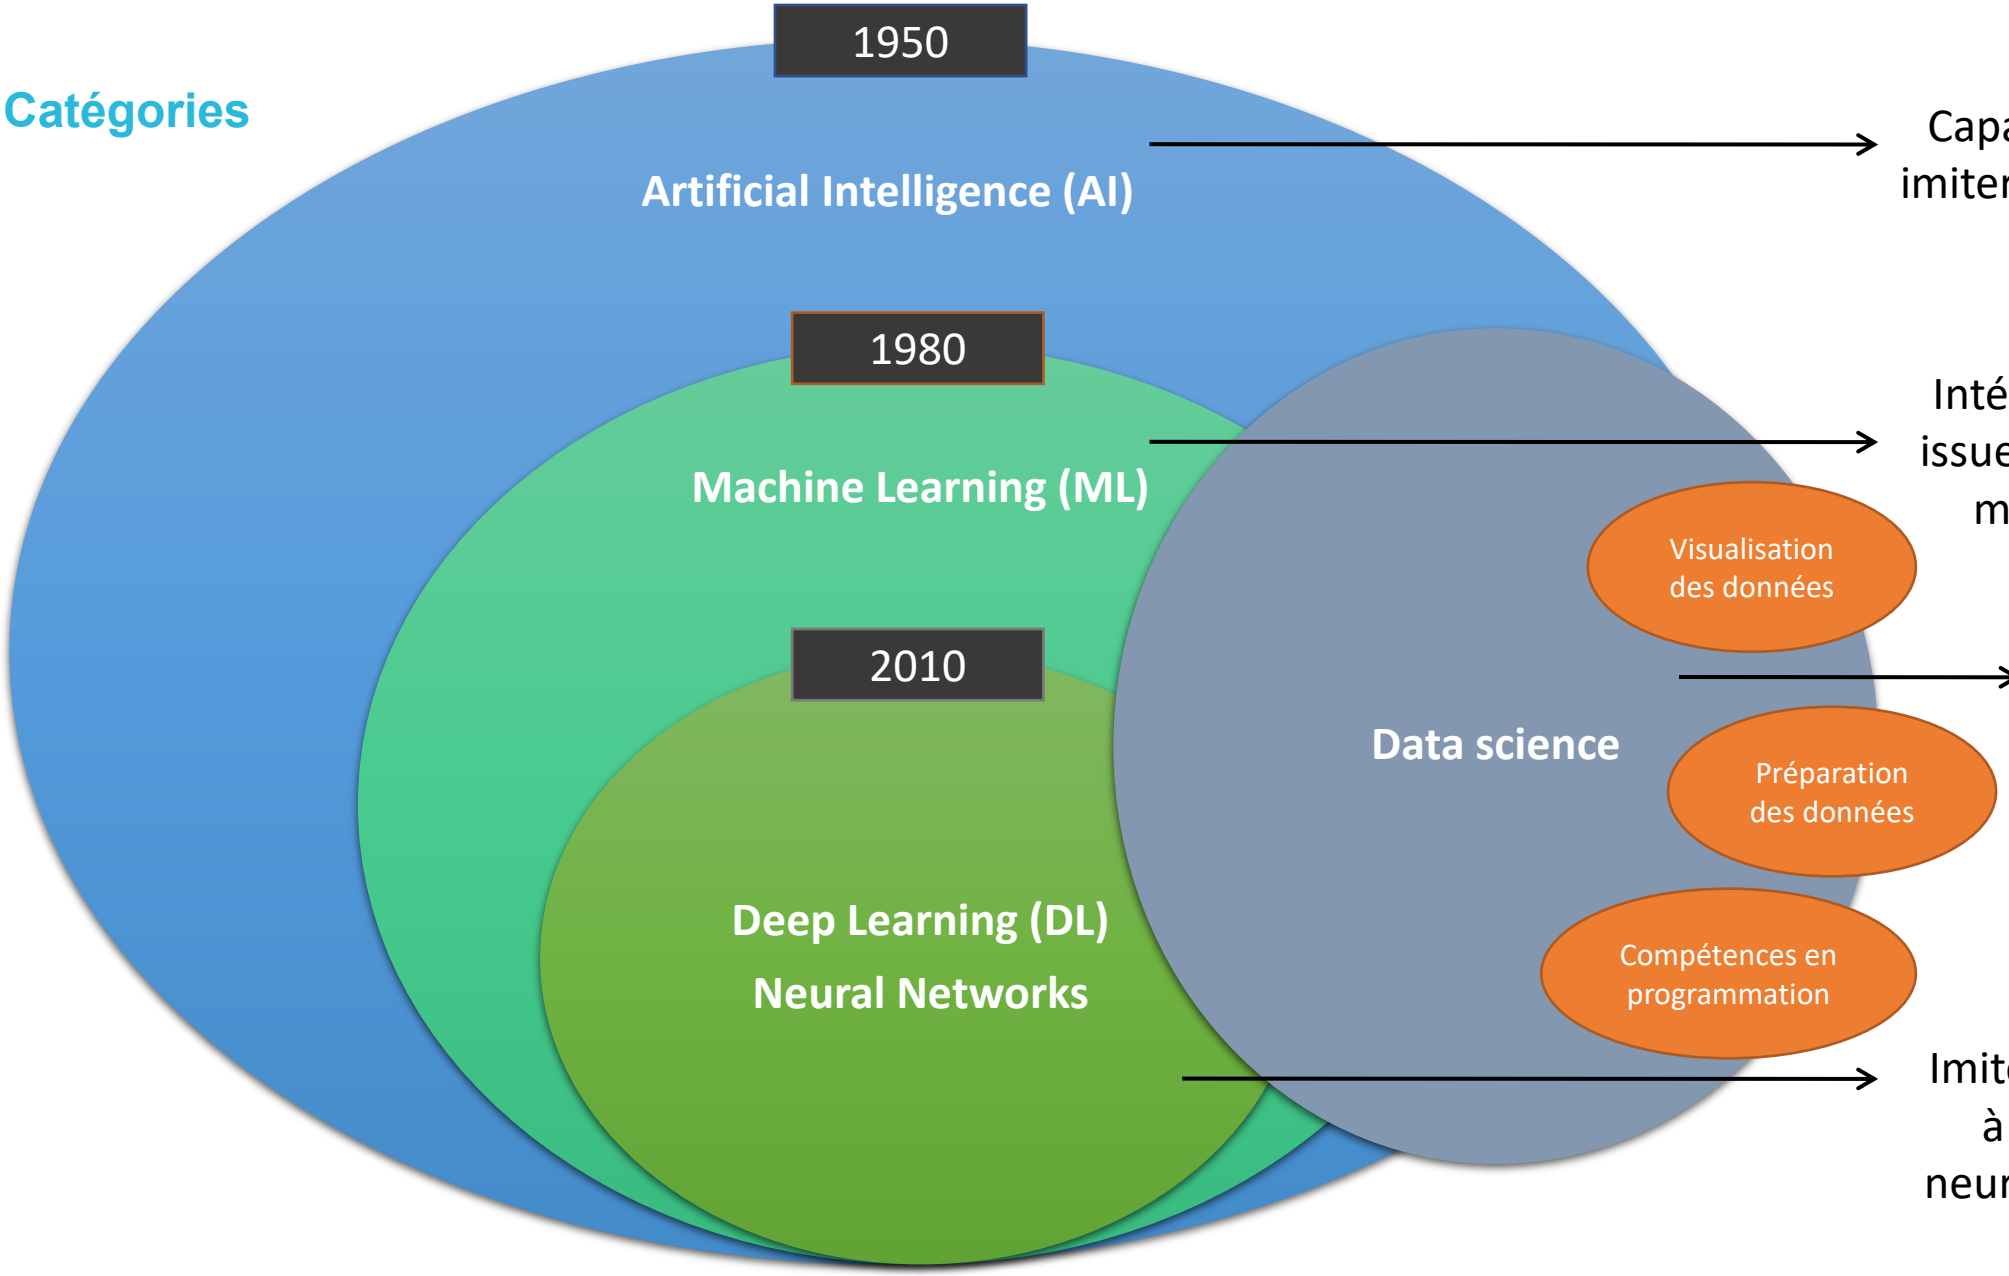

Capacité d'une machine à imiter l'intelligence humaine

Intégrer les informations issues d'algorithmes et de modèles statistiques

Extraire le sens et les informations utiles des données

Imite le cerveau humain à partir de réseaux neuronaux multicouches

Machine Vs. Deep leanring

Vers une extraction automatique des connaissances

Chien ou Chat ? Un problème de classification d'images

Objectif

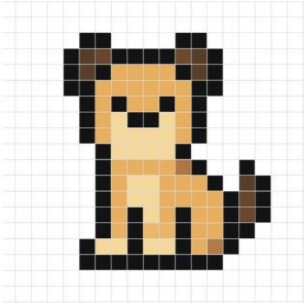

→ Modèle IA →

Chien

Chat

Image
224x224 pixels

Prédiction

Objectif *: apprendre à une machine à reconnaitre automatiquement si une image contient un chien ou un chat, sans règles codées à la main.*

Pourquoi c'est difficile ?

- *Variabilité de pose, couleur, fond, lumière, ….*
- *Des millions de pixels à interpréter*
- *Le même chien peut sembler très différent*

Deux grandes approches

Machine Learning (ML)

Features et méthode de classification sont dissociés

☑ ***Apprentissage rapide, contrôle humain, explicable*** ☒ ***Difficilement généralisable***

Deep Learning (DL)

Features extraites AUTOMATIQUEMENT pendant l'entrainement

☑ ***Généralisable, apprentissage automatique*** ☒ ***Nombre de données, peu explicable***

Comment représenter la donnée d'entrée ? (apprentissage manuel)

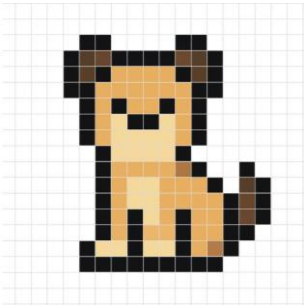

Concaténation des pixels

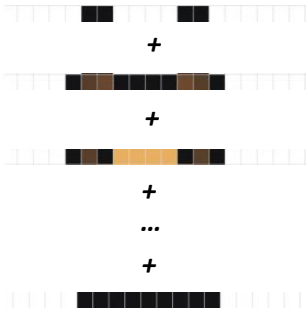

1 vecteur de taille [1,50176]

Histogrammes de couleurs (RGB)

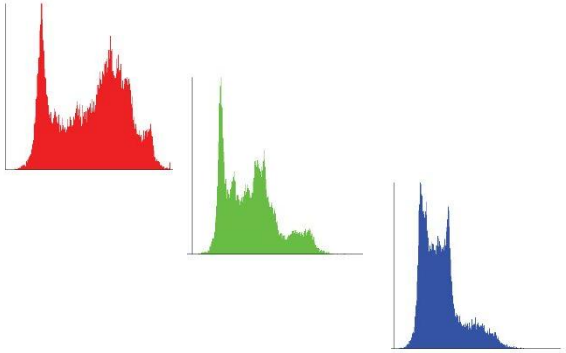

1 vecteur de taille [3,Bins]

Histogrammes de gradient (HOG)

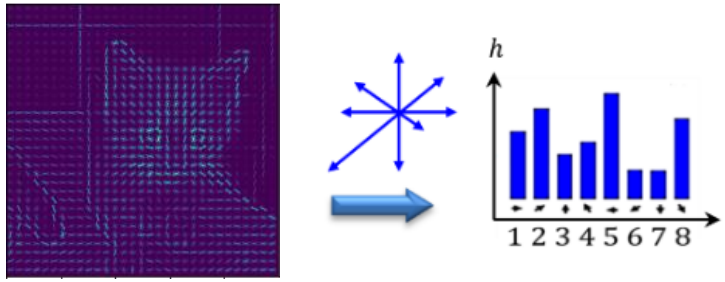

1 vecteur de taille [1,Bins]

Angle et Magnitude dans le temps

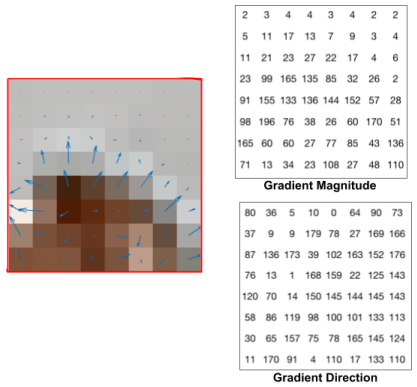

1 vecteur de taille [1, t, Bins]

Analyse Spatio-temporelle

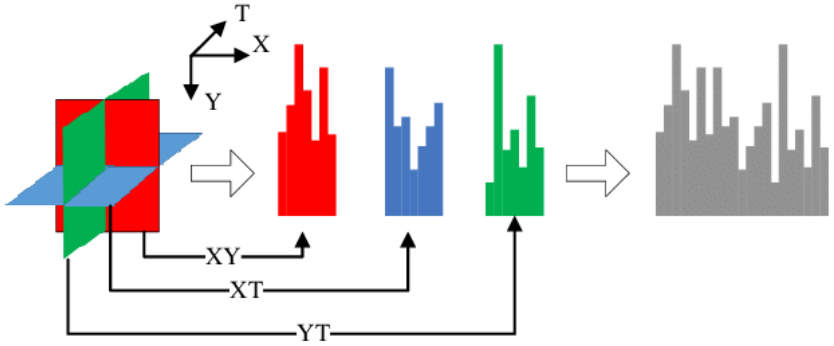

*1 vecteur de taille [1, t, 3*Bins]*

Classifieur de votre choix

- *Random Forest*
- *KNN*
- *SVM*
- *MLP*

Comment représenter la donnée d'entrée ? (apprentissage automatique)

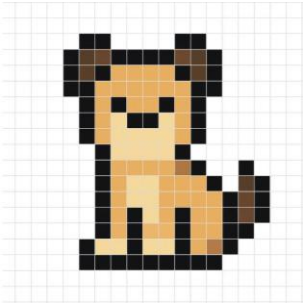

Concaténation des pixels

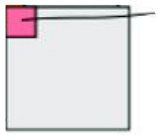

Vecteur de pixels

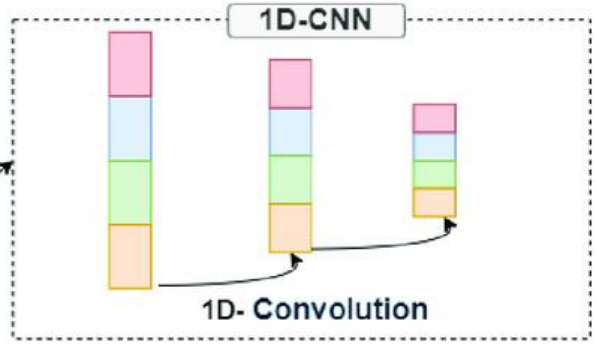

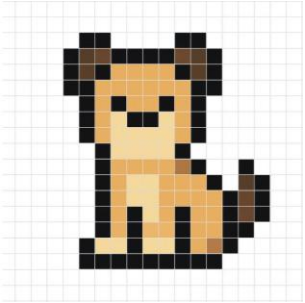

Features spatiales

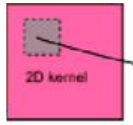

Patch 2D

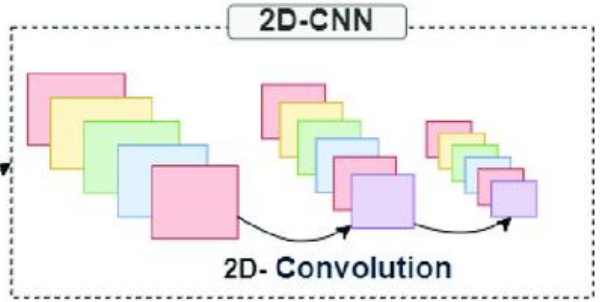

Features spatio-temporelles

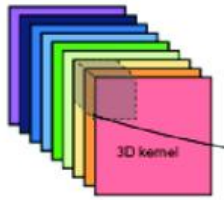

Patch 3D

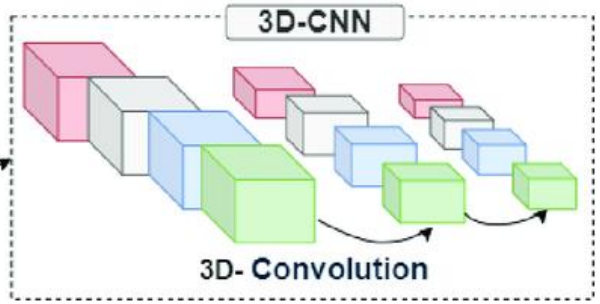

Classifieur de votre choix

- *Random Forest*
- *KNN*
- *SVM*
- *MLP*

Rétro-propagation

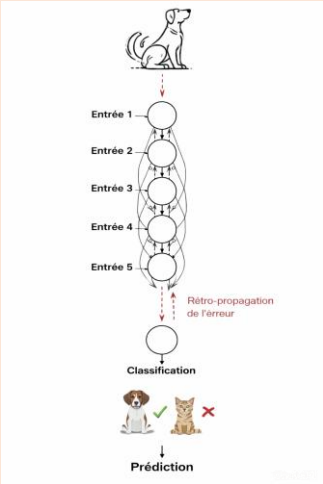

Les paradigmes d’apprentissage

Comment entrainer une IA ?

Les 3 paradigmes de l'apprentissage automatique

1 *Supervisé*

On apprend avec des étiquettes

La machine reçoit des milliers d'images ETIQUETEES « chien » ou « chat ». Elle apprendre la correspondance image ➔ Label

Analogie: comme un enfant qui apprend avec un adulte qui lui dit : « ça, c'est un chien »

Algos: SVM, Random Forest, CNN, RNN, …

Quand on dispose de données étiquetées en quantité

Cas chien/chat

1000 images étiquetées ➔ entrainement classifieur

2 *Non Supervisé*

On apprend sans étiquettes

La machine reçoit des images SANS étiquette. Elle cherche seule des groupes similaires (clusters) dans les données

Analogie: comme trier des photos en piles qui se ressemblent, sans savoir ce qu'elles représentent

Algos: K-means, Autocencodeurs, PCA

Quand on n'a pas de labels – exploration, compression

Cas chien/chat

Images sans labels ➔ regroupement automatique

3 *Par renforcement*

On apprend par essai/erreur

Un agent prend des décisions, reçoit une récompense (+) ou une pénalité (-) et ajuste sa stratégie pour maximiser ses gains

Analogie: comme dresser un chien : bonne action = récompense, mauvaise action = rien

Algos: Q-Learning, PPO, A3C, DQN

Quand on peut simuler un environnement avec des retours

Cas chien/chat

Agent joue, reçoit +1 bonne réponse, ajuste

Apprentissage supervisé

Pipeline d'entrainement

1. Dataset étiqueté

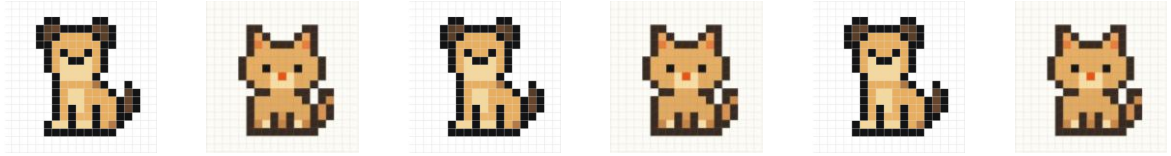

Chien | Chat | Chien | Chat | Chien | Chat

2. Entrainement du modèle

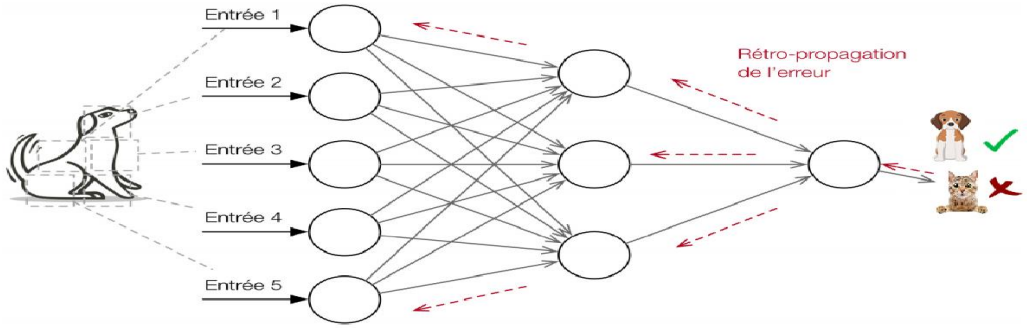

3. Prédiction sur nouvelle image

→ Modèle entrainé → Chien (96% conf.)

Points clés

Données annotées requises

Chaque image doit porter son label.

Annoter 50 000 images coûte du temps et de l'argent.

Fonction de perte (Loss)

Le modèle compare sa prédiction au vrai label et minimise l'erreur par rétropropagation

Généralisation

Le modèle doit bien performer sur des images JAMAIS vues.

On sépare train / validation / test.

☒ *Nécessite des milliers d'images ETIQUETEES à la main*

☑ *Très performant quand les données labellisées sont disponibles*

Apprentissage non supervisé

Pipeline d'entrainement

1. Images sans étiquettes

2. Algorithme de clustering (K-means, K = 2)

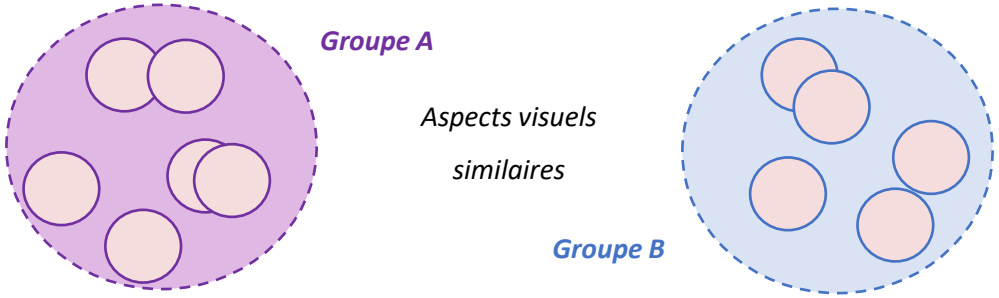

3. Prédiction sur nouvelle image

Points clés

Aucun label nécessaire

La machine reçoit uniquement les images brutes.

Idéal quand annoter est trop coûteux.

Découverte de structure

L'algorithme regroupe les images selon leurs similarités visuelles (textures, couleurs, formes, …)

Pas de vérité terrain

On ne sait pas si le groupe A = chien.

Il faut une interprétation humaine à postériori.

☒ *Les groupes n'ont pas de noms et sont difficile à identifier*

☑ *Très utile pour explorer de grands jeux de données non annotés.*

Apprentissage par renforcement

Pipeline d'entrainement

Contexte: Un agent voit une image et doit décider : « CHIEN » ou « CHAT ». A chaque bonne décision, il reçoit +1. A chaque erreur, il reçoit -1. Il apprend à maximiser son score.

AGENT		ENVIRONNEMENT
Choisit l'action	*Action: « CHIEN »* →	*Image + verdict*
	← *Récompense + 1*	

Exemples de récompenses :

Prédiction : « CHIEN »	***Récompenses : +1***	*Bonne prédiction*
Prédiction : « CHIEN »	***Récompenses : -1***	*Mauvaise prédiction*
Prédiction : « CHAT »	***Récompenses : +1***	*Bonne prédiction*
Prédiction : « CHAT »	***Récompenses : -1***	*Mauvaise prédiction*

Après chaque épisode : mise à jour de la politique → l'agent apprend quelle action maximise les récompenses cumulées

Points clés

Pas de données étiquetées

Aucun dataset avec labels. L'agent génère sa propre expérience en interagissant avec l'environnement.

Récompense différée

Les récompenses peuvent arriver bien après l'action. L'agent doit apprendre à planifier sur le long terme.

Exploration vs Exploitation

L'agent doit équilibrer : tester de nouvelles actions (explorer) ou répéter ce qui a marché (exploiter).

☒ *La définition de la politique initiale joue un rôle crucial*

☑ *Idéal pour robotique, jeux, systèmes de recommandation, conduite*

Préparation des données

Pourquoi préparer les données avant d'entrainer ?

Pipeline complet

Dataset brut

ID	Label	Bright	Ctrst	KB
001	chien	142	0.82	210
002	**CHAT**	**NaN**	1.45	875
003	chien	**251**	**0.01**	124
004	chat	108	0.91	1540
005	**-**	115	0.88	95
006	chien	134	**4.70**	212
006	chien	134	4.70	212
007	chat	98	0.77	330
008	chat	122	1.02	415
009	chien	108	0.92	180

1 Data Cleaning

Valeurs manquantes ▪ Outliers
Doublons ▪ Labels erronés

NaN → médiane | z > 3 → retiré | CHAT → chat

2 Data Réduction

PCA▪ Sélection de features
Curse of dimensionality

2048 features CNN → 48 composantes PCA (-97%)

3 Data Scaling

Min-Max ▪ Z-score
Robust Scaling

Brightness [0-255] → [0,1] | Contrast → u = 0 a = 1

4 Data Transformation

Encodage labels
Augmentation des données

chien → 0 chat → 1 | x8 images augmentées par flip/rotation

Règles : Tous les paramètres doivent être calculés UNIQUEMENT sur le Train set, puis appliqués au Val/Test pour ne pas gonfler les performances

Nettoyer le dataset

1 Valeurs manquantes (NaN)

Avant

ID	Label	Bright	Ctrst
IMG1	chien	142	0.82
IMG2	chat	NaN	1.45
IMG3	chien	108	NaN

Après

ID	Label	Bright	Ctrst
IMG1	chien	142	0.82
IMG2	chat	119	1.45
IMG3	chien	108	0.91

Imputation par la MEDIANE du groupe (chien/chat séparément).
Jamais la moyenne globale – les deux classes ont des distributions différentes de brightness.

2 Outliers – Valeurs aberrantes

Avant

ID	Label	Bright	Ctrst
IMG3	chien	251	0.61
IMG6	chien	134	4.70
IMG8	chat	101	0,85

Après

ID	Label	Bright	Ctrst
retiré	-	-	-
retiré	-	-	-
IMG8	chat	101	0.85

Détection par Z-score (|z| > 3) ou règle IQR × 1.5. Option 1 : retirer.
Option 2 : plafonner au percentile 95. Ici suppression car artefact matériel confirmé.

3 Doublons

Avant

ID	Label	Bright	Ctrst
IMG5	chien	115	0.82
IMG6	chien	134	0.93
IMG7	chien	134	0.93

Après

ID	Label	Bright	Ctrst
IMG1	chien	142	0.82
IMG2	chat	119	1.45
retiré	-	-	-

Calculer le hash MD5 (ou SHA-256) de chaque image. Conserver une seule occurrence.
Supprimer images corrompues : taille=0 Ko ou résolution 1×1 px

4 Labels incohérents

Avant

ID	Label	Bright	Ctrst
IMG2	CHAT	98	1.45
IMG5	-	115	0.88
IMG9	Chien	108	0,93

Après

ID	Label	Bright	Ctrst
IMG2	chat	98	1.45
retiré	-	-	-
IMG9	chien	108	0.93

Normaliser labels : .lower().strip(). Images sans label : retirer ou re-annoter.
Classes finales autorisées : {'chien', 'chat'} uniquement.

Normaliser et Standardiser les features

Problème : sans scaling, la brightness (0-255) domine artificiellement le contrat (0-5) dans tout calcul de distance ou de gradient.
Le modèle apprend l'échelle des features, pas leur contenu.

Min – Max Normalisation

x' = (x – min) / (max – min) → [0, 1]

Avant :

142 98 201 67 115

Après :

0,56 0,38 0,79 0,26 0,45

- ✅ Préserve la distribution. Bornes fixes.
- ❌ Très sensible aux outliers restants
- ⚙ CNN – images pixel – features bornées

Z-score Standardisation

x' = (x – μ) / σ → μ=0, σ=1

Avant :

142 98 201 67 115

Après :

0,6 -0,33 1,64 -1,18 -0,07

- ✅ Standard pour la majorité des modèles
- ❌ Pas de bornes fixes
- ⚙ SVM – régression – réseaux denses

Robust Scaling

x' = (x – médiane) / IQR

Avant :

142 98 201 67 115

Après :

0,43 -0,22 1,35 -1,08 -0,05

- ✅ Robuste aux outliers résiduels
- ❌ Moins standard, moins répandu
- ⚙ Données avec outliers persistants

Encoder, Rééquilibrer, Augmenter

1 Encodage des labels

Binaire – 1 colonne :

ID	Label		Num.
IMG1	chien	→	0
IMG2	chat	→	1
IMG3	chien	→	0

Multi-classes → One-Hot :

ID	Label	Chien	Chat	Lapin
IMG1	chien	1	0	0
IMG2	chat	0	1	0
IMG3	chien	0	0	1

Ne jamais encoder les labels AVANT le split train/val/test

2 Corriger la distribution

Avant log :

Après log(x+1) :

X' = log (x+1) → distribution symétrique. Convergence plus rapide.

3 Augmentation des données

1 photo de chien → 5 images augmentées.

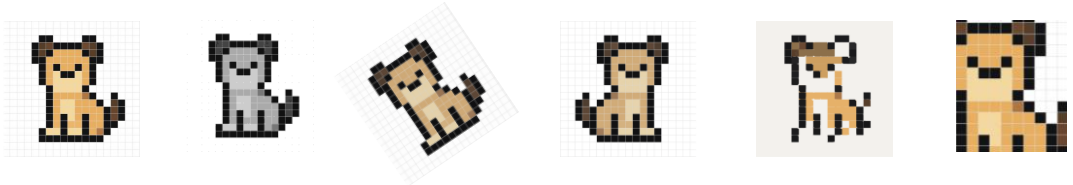

couleur *rotation* *flip* *contraste* *crop*

4 Rééquilibrage des classes

Avant:

Undersampling	*Réduire chiens. Simple mais perd de l'info.*
Oversampling	*Copier chats. Risque d'overfitting.*
SMOTE	*Générer des chats synthétiques.*
Poids de classe	*Class_weight = {chat:4}.*

Le protocole de validation

Comment aider la généralisation du modèle ?

Pourquoi évaluer un modèle ?

Le problème : overfitting

Mémorisation

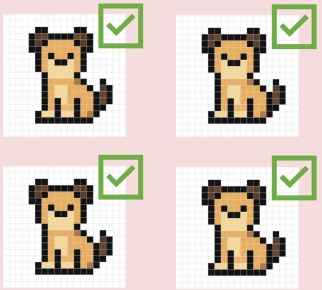

Train :

100%

Nouvelle image

Chat

Test :

42%

Le modèle à juste mémorisé !

Règle d'or : Ne JAMAIS évaluer sur les données d'entrainement. On a besoin de données que le modèle n'a jamais vues.

4 protocoles couverts dans ce cours :

- *Train / Val / Test* — *- Split unique en 3 parties*
- *K-Fold CV* — *- K rotations, tous testés*
- *Stratified K-Fold* — *- K-Fold + équilibre classes*
- *LOSO* — *- Leave One Subject Out*

Vocabulaire essentiel

Jeu d'entrainement

Images utilisées pour ajuster les poids du modèle.
Ex : 7000 photos chien/chat étiquetées.

Jeu de validation

Images pour régler les hyperparamètres (learning rate, profondeurs, …)
Ex : 1500 photos. Ne sert PAS à entrainer.

Jeu de test

Images jamais vues, utilisées UNE SEULE FOIS en fin de projet
Ex : 1500 photos, Reflète les performances réelles.

Biais de sélection

Si train et test viennent du même chien photographié 50 fois, les performances sont artificiellement gonflées

Métriques d'évaluation classiques :

Accuracy *(nb. Bons / total)* ***F1 score*** *(harmonie précision/rappel)*

Protocole Train / Validation / Test – Le split unique

Dataset complet : 10 000 images (5000 chiens + 5000 chats)

TRAIN – 7000 (70%)	VAL – 1500 (15%)	TEST – 1500 (15%)

TRAIN – Apprendre les paramètres

Quand ? Durant chaque epoch d'entrainement

Le modèle voit ces images ET leurs labels. Il ajuste ses poids par rétropropagation pour minimiser la loss.

Ex : 3500 chiens étiquetées CHIEN + 3500 chats étiquetés CHAT

Ne jamais évaluer les performances finales sur cette partie !

VAL – Régler les hyperparamètres

Quand ? Après chaque epoch

On mesure la loss de validation. Si elle remonte – overfitting.

750 chiens + 750 chats non vus

Utilisé plusieurs fois, ne remplace pas test.

Signal d'overfitting : loss train continue de baisser mais la loss val remonte – arrêter l'entrainement (Early Stopping).
Signal d'underfitting : les deux losses restent hautes – modèle trop simple.

TEST – Evaluation finale unique : 1500 images jamais vues (750 chiens, 750 chats).
On l'ouvre UNE SEULE FOIS, tout en dernier. L'accuracy obtenue ici est celle qu'on publie.

Validation croisée K-Fold & K-Fold Stratifié

K-Fold Cross Validation (K = 5)

	Fold 1	Fold 1	Fold 1	Fold 1	Fold 1	
Iter 1	**TEST**	TRAIN	TRAIN	TRAIN	TRAIN	**Acc : 82%**
Iter 2	TRAIN	**TEST**	TRAIN	TRAIN	TRAIN	**Acc : 82%**
Iter 3	TRAIN	TRAIN	**TEST**	TRAIN	TRAIN	**Acc : 82%**
Iter 4	TRAIN	TRAIN	TRAIN	**TEST**	TRAIN	**Acc : 82%**
Iter 5	TRAIN	TRAIN	TRAIN	TRAIN	**TEST**	**Acc : 82%**

Résultat final = moyenne des 5 scores : Acc = 81.8 +/- 1.8%

***Avantage** : Chaque image sert de test une fois estimation robuste. Idéal pour les petits datasets.*

Coût calcul * K fois plus élevé qu'un simple split.

Stratified K-Fold CV (K = 5)

Problème : dataset déséquilibré

Sans stratification, distribution aléatoire dans chaque fold:

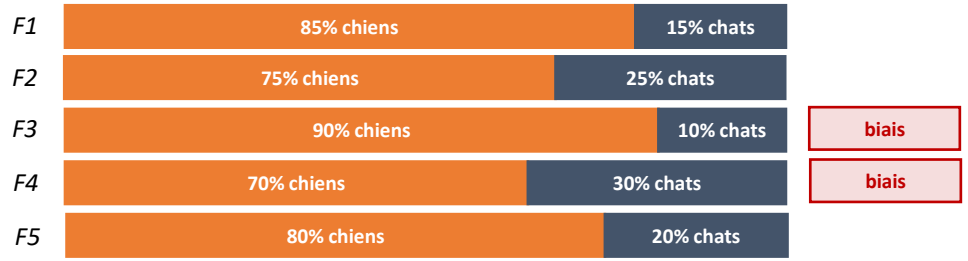

Avec stratification, même distribution dans chaque fold:

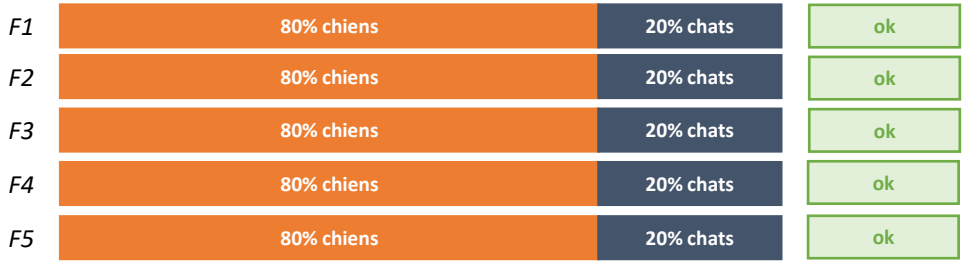

Chaque fold reflète fidèlement la distribution du dataset

Leave One Subject Out (LOSO)

Problème motivant : Notre dataset contient des photos de 6 chiens et 4 chats spécifiques.
Si le même chien apparait entre TRAIN et TEST, le modèle a juste mémorisé CE chien – pas appris à généraliser à de nouveaux animaux.

Dataset : 10 sujet distincts (6 chiens : D1-D6 ▪ 4 chats C1-C4) ▪ ~100 photos/sujet

Déroulement LOSO – 10 itérations (une par sujet) :

Iter 1 : Test = D1	**TEST**	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	**Acc : 78%**
Iter 4 : Test = D4	TRAIN	TRAIN	TRAIN	**TEST**	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	**Acc : 82%**
Iter 7 : Test = C1	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	**TEST**	TRAIN	TRAIN	TRAIN	**Acc : 75%**
Iter 10 : Test = C4	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	TRAIN	**TEST**	**Acc : 80%**

Résultat final = moyenne des 10 itérations : Acc = 79.5% +/- 2.4% Performance réelle sur de NOUVEAUX sujets

Avantages : Mesure la vraie capacité de généralisation

Limites : très coûteux si N sujets est grand

Cas concrets

Quelques exemples pour valider vos connaissances

CAS 01

Détection de maladie cutanée

Contexte : Un hôpital dispose de 2 000 photos de lésions cutanées issues de 100 patients (≈20 photos/patient).

Objectif : classer 3 types de lésions (bénigne, précancéreuse, maligne).
3 dermatologues ont pris les photos avec des appareils différents.

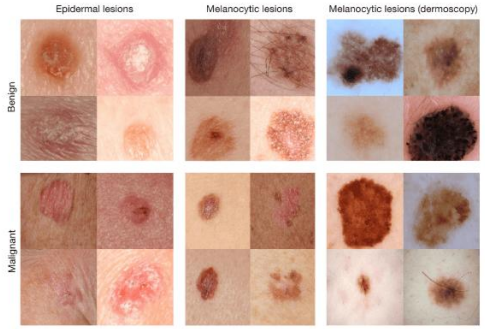

Préparation des données	? *Comment homogénéiser les prises de vue des différents appareils ? Peu de données (2 000 images)*	*Normalisation colorimétrique + augmentation*
Stratégie d'apprentissage	? *Comment entrainer le modèle quand on dispose des labels ?*	*Approche Supervisée*
Extraction de features	? *Quelles représentations capturent les caractéristiques d'une lésion ?*	*Descripteur spaial 2D*
Protocole de validation	? *Comment valider sans biaiser les résultats avec des données groupées par patient ?*	*LOSO – Leave One Subject Out - ACC*

CAS 02

Contrôle qualité en usine – détection de défauts

Contexte : Une usine produit des pièces métalliques.
Dataset : 800 photos — 720 pièces conformes / 80 défectueuses (10%).

Objectif : détecter les défauts en temps réel sur la chaîne.
Les défauts sont rares mais critiques : un défaut non détecté coûte très cher.

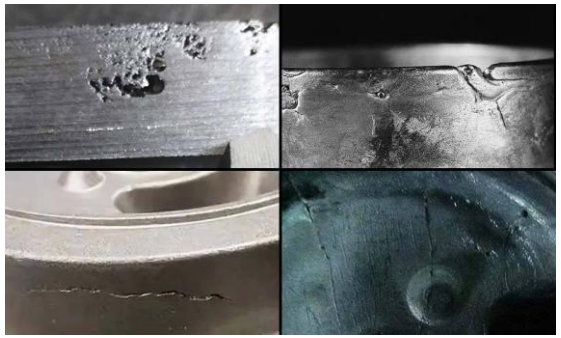

Préparation des données	? *Classes très déséquilibrées (90/10) — comment compenser le manque d'exemples rares ?*	*Augmentation (rotation / flip)*
Stratégie d'apprentissage	? *Comment entrainer le modèle quand on dispose des labels ?*	*Approche Supervisée*
Extraction de features	? *Quelles features capturent des irrégularités de surface (rayures, craquelures) ?*	*Descripteur spaial 2D*
Protocole de validation	? *Comment valider de façon fiable avec seulmeent 80 exemples défectueux ?*	*Stratified K-Fold (K=5) – F1 score*

CAS 03

Analyse de performance sportive – détection d'actions

Contexte : Un club de football dispose de vidéos de 20 matchs.

Objectif : détecter automatiquement les actions clés (tir, passe, dribble, faute).
Chaque match = 90 min à 25fps ≈ 135 000 frames.
Les équipes et les conditions de jeu varient d'un match à l'autre.

Préparation des données	? *Comment gérer la grande variété des conditions de captation et du temps d'enregistrement ?*	*Normalisation + Crop temporal (fenêtre)*
Stratégie d'apprentissage	? *Comment entrainer le modèle quand on ne dispose pas des labels ?*	*Approche Non Supervisée*
Extraction de features	? *Comment représenter le mouvement et la posture des joueurs ?*	*Géométrie (pose) + temporal*
Protocole de validation	? *Comment valider sans créer de fuite temporelle entre matchs ?*	*Leave One Match Out (LOSO)*