IMT Nord Europe
École Mines-Télécom
IMT-Université de Lille

Techniques de validation croisée

Arthur Louchart

UV Data Sciences – 24.03.26

Introduction à la validation croisée

- Évaluer la performance d'un modèle de manière fiable.
- Réduire le sur-apprentissage (*overfitting*).

Découpage simple : Train/Test

- Divise le jeu de données en deux ensembles : Train et Test.
- Exemple classique : 70% train / 30% test.
- Simple mais sensible à la partition choisie.

- Possibilité de découper en Train/Validation/Test
- L'ensemble Validation permet de choisir parmi les meilleurs modèles entrainés sur l'ensemble Test

Validation croisée K-Fold

Objectif : estimer de manière plus fiable les performances et aide à prévenir l'overfitting

- Divise le jeu de données en K folds (exemple : $K = 3$).

- Chaque fold sert de test une fois.

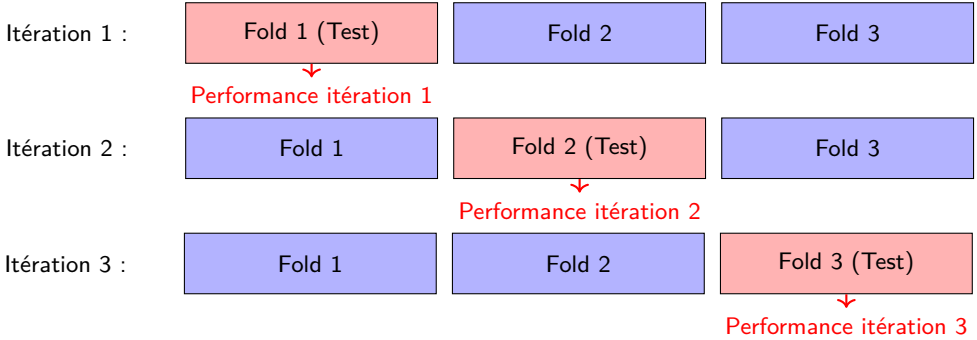

- Performance finale = moyenne des K performances.

Groupe K-Fold

- Même philosophie que K-Fold
- Utilisé lorsque certaines observations appartiennent à un même groupe (exemple avec 4 sujets).

Sujet 1	Sujet 2	Sujet 3	Sujet 4

- Assure qu'un même groupe n'est pas divisé entre train et test. (exemple avec 2 groupe)

Itération 1 :	Sujet 1	Sujet 2	Sujet 3	Sujet 4
Itération 2 :	Sujet 1	Sujet 2	Sujet 3	Sujet 4

- Performance finale = moyenne des K performances.

Exemple avec Groupe K-Fold

```
from sklearn.model_selection import GroupKFold

subjects = list(range(1, 33))  # Sujet 1 -> Sujet 32

gkf = GroupKFold(n_splits=5)

for fold, (train_idx, val_idx) in enumerate(gkf.split(subjects, groups=subjects)):
  print(f"\n===== FOLD {fold+1} =====")

  train_subjects = [subjects[i] for i in train_idx]
  val_subjects   = [subjects[i] for i in val_idx]

  print("Train:", train_subjects)
  print("Val:", val_subjects)
```

Leave-One-Subject-Out (LOSO)

- Cas particulier de Groupe K-Fold : un sujet par test fold.
- Chaque itération : $n-1$ sujets pour l'entraînement, 1 sujet pour le test (exemple avec $n=4$ sujets)

Itération 1 :	Sujet 1	Sujet 2	Sujet 3	Sujet 4
Itération 2 :	Sujet 1	Sujet 2	Sujet 3	Sujet 4
Itération 3 :	Sujet 1	Sujet 2	Sujet 3	Sujet 4
Itération 4 :	Sujet 1	Sujet 2	Sujet 3	Sujet 4

- **Très longs pour les grands jeux de données**

Résumé des techniques

Technique	Avantages	Inconvénients
Train/Test fixe	Simple	Forte variance
K-Fold	Stable	Pas de garantie sur groupes
Groupe K-Fold	Pas de fuite de groupes	Complexe si beaucoup de groupes
LOSO	Test sur chaque sujet	Coûteux pour grands datasets